大作业: 实现 AQL Subset

编译原理

# 什么是AQL?

- ▶ 全称: Annotation Query Language
- ▶ 用于Text Analytics。可以从非结构化或半结构化的文本中提取结构化信息的语言。
- ▶ 语法类似于SQL



# 什么是AQL subset?

- ▶ AQL语法复杂,功能强大,实现难度较高
- ▶ AQL 子集具有AQL的主要特点



## 名词定义

- ▶ Token:以字母或者数字组成的无符号分隔的字符串, 或者单纯的特殊符号,不包含空白符(blank)。
  - Eg: I am strong, and I don't like eating light-blue lollipop.

ı	am	strong	,
and	ı	don	i
t	like	eating	light
-	blue	lollipop	•



# 名词定义

Span:由正则表达式提取出来的具有位置信息的字符串,可以是完整的Token,也可以是不完整的(半个或者多个)。

view: 类似于数据库的Table,可以分为多个属性列, 列中的行单元为Span。



# AQL 子集

- 主要操作:
  - ▶ create view (创建view)
    - ▶ extract regex (利用正则从文本中提取span)
    - extract pattern (利用正则和view在原文本中匹配符合的模式)
    - ▶ select (在view中选列)
  - ▶ output view (格式化打印view)



举例

# AQL subset 示例

- ▶ **任务**:将人名和人名对应的地名从文本中提取出来
  - ▶ 人名: 大写字母开头的Token
  - ▶ **地名**: 两个以大写字母开头的Tokens,并且中间以逗号分隔,其中第二个单词是美国的州名
  - ▶ 文本: (下划线代表空格, 会被忽略)
    Carter\_from\_Plains,\_Georgia,\_Washington\_from\_
    Westmoreland,\_Virginia



# AQL subset 示例

#### 输入:

```
Carter_from_Plains,_Georgia,
1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28
```

\_ Washington\_from\_Westmoreland, \_ Virginia 29 30 31 32 33 34 35 36 37 38 39 40 41 42 43 44 45 46 47 48 49 50 51 52 53 54 55 56 57 58 59 60 61 62 63 64 65 66 67



Carter\_from\_Plains,\_Georgia,
1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28

<u>Washington\_from\_Westmoreland</u>, <u>Virginia</u> 29 30 31 32 33 34 35 36 37 38 39 40 41 42 43 44 45 46 47 48 49 50 51 52 53 54 55 56 57 58 59 60 61 62 63 64 65 66 67

#### 从文本中提取出大写字母开头的单词

#### Eg:

Carter(1,7)

Plains(13,19)

Georgia(21,28)

Washington(30,40)

Westmoreland(46,58)

Virginia(60,68)



Carter\_from\_Plains,\_Georgia,
1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28

<u>Washington\_from\_Westmoreland</u>, <u>Virginia</u> 29 30 31 32 33 34 35 36 37 38 39 40 41 42 43 44 45 46 47 48 49 50 51 52 53 54 55 56 57 58 59 60 61 62 63 64 65 66 67

#### 从文本中提取出美国的州名

#### Eg:

Georgia(21,28) Washington(30,40) Virginia(60,68)



Carter\_from\_Plains,\_Georgia,
1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28

\_ Washington\_from\_Westmoreland, \_ Virginia 29 30 31 32 33 34 35 36 37 38 39 40 41 42 43 44 45 46 47 48 49 50 51 52 53 54 55 56 57 58 59 60 61 62 63 64 65 66 67

按照中间只<mark>隔了一个逗号,且后一个单词为州名</mark>即为一个地名的规则, 拼接上述两部操作得到的字符串列表 Eg:

Plains, Georgia(13,28) Georgia, Washington(21,40) Westmoreland, Virginia(46,68)



Carter\_from\_Plains,\_Georgia,
1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28

<u>Washington\_from\_Westmoreland</u>, <u>Virginia</u> 29 30 31 32 33 34 35 36 37 38 39 40 41 42 43 44 45 46 47 48 49 50 51 52 53 54 55 56 57 58 59 60 61 62 63 64 65 66 67

#### 大写字母开头的为人名

#### Eg:

Carter(1,7)
Plains(13,19)
Georgia(21,28)
Washington(30,40)
Westmoreland(46,58)
Virginia(60,68)



Carter\_from\_Plains,\_Georgia,
1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28

<u>Washington\_from\_Westmoreland</u>, <u>Virginia</u> 29 30 31 32 33 34 35 36 37 38 39 40 41 42 43 44 45 46 47 48 49 50 51 52 53 54 55 56 57 58 59 60 61 62 63 64 65 66 67

人名与地名相对应的规则为相隔1-2个tokens,

根据此规则拼接人名和地名的列表

Eg:

人名 地名 人名-地名

Carter Plains, Georgia Carter from Plains, Georgia

Plains Georgia, Washington Plains, Georgia, Washington

Georgia Westmoreland, Virginia Georgia 无匹配

Washington Washington from Westmoreland, Virginia

Westmoreland Westmoreland 无匹配

Virginia Virginia 无匹配



<u>Washington\_from\_Westmoreland</u>, <u>Virginia</u> 29 30 31 32 33 34 35 36 37 38 39 40 41 42 43 44 45 46 47 48 49 50 51 52 53 54 55 56 57 58 59 60 61 62 63 64 65 66 67

#### 最终我们得到三个列表

#### Eg:

八石	地石	八石-地石
Carter	Plains, Georgia	Carter from Plains, Georgia
Plains	Georgia, Washington	Plains, Georgia, Washington
Georgia	Westmoreland, Virginia	Washington from Westmoreland, Virginia

Washington

Westmoreland

Virginia



# 利用AQL

## create view: regex语句

▶ 提取第一个字母大写的token

```
create view Cap as
  extract regex /[A-Z][a-z]*/
  on D.text as Cap
  from Document D;
```

#### 注意:

- 1、view与数据库table类似,是可以具有多个属性列的表格。
- 2、view后的Cap是view的名字。
- 3、'/'包括起来的是正则表达式,内部含有需转义。
- 4、Document是默认的view,指代当前输入文本。
- D是Document的别名。text是Document的一个属性列,存储的文本。



# create view: regex语句

提取美国州名 create view Stt as extract regex /Washington|Georgia|Virginia/ on **D.text** return group 0 as Stt from Document D; View: Stt Stt Georgia: (20,27) Washington: (29,39) Virginia: (59,67) rows in set

#### 注意:

- 1、return group 给属性列命名。
- 2、group 0是匹配的全部,即整个正则所匹 配的内容。
- 3、没有写return语句,只有as ID 默认为 return group 0 as ID(如上一张)。

## create view: pattern语句

```
create view Loc as
  extract pattern (<C.Cap>) /,/ (<S.Stt>)
  return group 0 as Loc
   and group 1 as Cap
  and group 2 as Stt
  from Cap C, Stt S;
```

Plains:(12,18)   Plains, Georgia:(12,27)   Georgia:(20,27)   Georgia:(20,27)   Georgia, Washington:(20,39)   Washington:(29,39)   Westmoreland:(45,57)   Westmoreland, Virginia:(45,67)   Virginia:(59,67)	+   Cap	+   Loc	+   Stt
	Georgia:(20,27)	Georgia, Washington:(20,39)	Washington:(29,39)

3 rows in set

#### 注意:

Cap和Stt为之前两步建立的view。group1和group2为Loc的两个属性列。 pattern的作用是利用正则和现成的span在文本中匹配符合的模式。



# create view: regex语句

```
create view Per as
  extract regex /[A-Z][a-z]*/
  on D.text
  return group 0 as Per
  from Document D;
```

#### 注意:

- 1、这里与前面的Cap一模一样。
- 2、再次强调:提取出来的每个字符串叫做span。span存储在view的属性列中。

### create view: pattern语句

create view PerLoc as

▶ 拼接人名与地名,要求只相隔1-2个Token

```
extract pattern (<P.Per>) <Token>{1,2} (<L.Loc>)
  return group 0 as PerLoc
     and group 1 as Per
     and group 2 as Loc
  from Per P, Loc L;
View: PerLoc
                             Per
                                               PerLoc
 Loc
                                               | Carter from Plains, Georgia:(0,27)
 Plains, Georgia: (12,27)
                            | Carter:(0,6)
 Georgia, Washington: (20,39)
                             Plains:(12,18)
                                                Plains, Georgia, Washington: (12,39)
 Westmoreland, Virginia: (45,67)
                              Washington: (29,39)
                                                Washington from Westmoreland, Virginia: (29,67)
```

#### 注意:

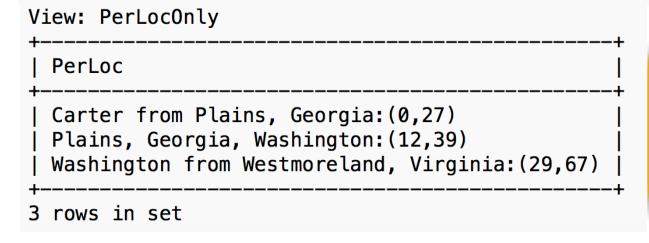
3 rows in set

- 1、pattern中用圆括号包含的部分类似于「子表达式捕获」,group 0捕获整个pattern, group 1捕获第一个括号包含的部分作为属性列, group 2同理。
  - 2、Token 是一个关键字,用来表达中间相隔了token。{min,max}表达重复。

### create view: select语句

▶ 从现成的view中选列

create view PerLocOnly as
 select PL.PerLoc as PerLoc
 from PerLoc PL;



#### 注意:

1、PerLoc这个view有三 个列Loc、Per以及 PerLoc。这里选择了 PerLoc列。



# create view: output语句

#### 輸出语句

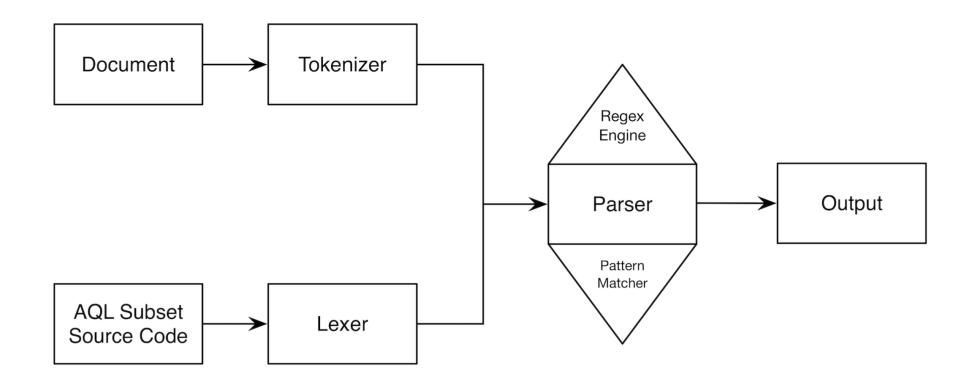
```
output view Cap;
output view Stt;
output view Loc;
output view Per;
output view PerLoc;
output view PerLocOnly;
```

#### 注意:

之前所有的语句的输出都是利用输出语句格式化打印出来的。



### Procedure





语法



```
aql_stmt → create_stmt; I output_stmt;

create_stmt → create view ID as view_stmt
view_stmt → select_stmt I extract_stmt

output_stmt → output view ID alias
alias → as ID | ε
```

#### Eg:

```
output view Cap;
output view Stt;
output view Loc as L;
output view Per as P;
```



select PL.PerLoc as PerLoc

from PerLoc PL;

```
Select Statement

select_stmt → select select_list from from_list
select_list → select_item | select_list , select_item
select_item → ID . ID alias
from_list → from_item | from_list , from_item
from_item → ID ID

list->item subltem subltem->eps | , list
Eg:
create view PerLocOnly as
```

\_\_

```
Extract Statement—Regular Expression
extract_stmt → extract extract_spec from from_list
extract_spec → regex_spec | pattern_spec
regex_spec → regex REG on column name_spec
column → ID . ID
name_spec → as ID | return group_spec
group_spec → single_group | group_spec and single_group single_group → group NUM as ID
     group_spec->single_group subSingle_group
Eg:
   create view Per as subSingle_group->eps I and group_spec
       extract regex /[A-Z][a-z]*/
           on D.text
           return group 0 as Per
       from Document D;
```

```
Extract Statement—Sequence Pattern
pattern_spec → pattern pattern_expr name_spec
pattern_expr → pattern_pkg I pattern_expr pattern_pkg
pattern_pkg → atom | atom { NUM, NUM } | pattern_group
atom → < column > I < Token > I REG
pattern_group → ( pattern_expr )
     pattern_expr->pattern_pkg subPattern_pkg
Eg:
                           subPattern_pkg->eps I pattern_expr
   create view PerLoc as
       extract pattern (<P.Per>) <Token>{1,2} (<L.Loc>)
           return group 0 as PerLoc
             and group 1 as Per
      and group 2 as Loc
from Per P, Loc L; pattern_pkg->atom range I parttern_group
```

range->eps I {NUM, NUM}



## 关键字

关键字如下,大小写敏感。

create, view, as, output, select, from, extract, regex, on, return, group, and, Token, pattern



实现细节



# Implementation

- Interpreter
  - Lexer
  - Parser
- Text Tokenizer
- Pattern Matcher
- ▶ Regular Expression Engine (已提供)



### 实现细节: 词法分析器 lexer

- 建议AQL的每个token都记录行号、列号,方便进行词 法错误的提示
- extract regex /正则表达/,使用了 '/' 来包含正则表达式,可以在词法分析时忽略前后的'/',将正则表达式整体作为一个token保存并返回给语法分析



# 实现细节: 语法分析器 parser

- 递归下降的语法分析,禁止自底向上
- 在写代码时,语法的产生式可以自行调整,只要符合规定的语法规则
- ▶ 建议阅读《编译原理》课本的附录A



# 实现细节: 正则表达式引擎

- ▶ 无需写,提供regex.cpp及接口函数findall。
- ▶ regex.cpp实现了NFA方式的正则引擎
- > 支持特性:
  - ▶ 连接、选择、任意
    - ab, alb, .
  - ▶ 重复(贪婪与非贪婪模式)
    - \*, +, ?, \*?, +?, ??
  - 转义
    - ▶ \r, \n, \t
  - > 字符类
    - ▶ [a-zA-Z0-9\_]
  - 捕获与非捕获
    - ▶ a(b)c, a(?:b)c
  - 全文多次匹配
    - ▶ [a-zA-Z0-9\_]能够找到文本中所有的标识符,而不仅仅是匹配第一个找到的



# 实现细节: 正则表达式引擎

#### ▶ 正则文法

```
regex → alt
alt → concat | alt '|' concat
concat → repeat | concat repeat
repeat → single
          | single '*' | single '*' '?'
           | single '+' | single '+' '?'
          | single '?' | single '?' '?'
single \rightarrow '(' alt ')'
          | '(' '?' ':' alt ')'
          | '.' | CHAR | CHARCLASS
```



## 实现细节: 正则表达式引擎

- ▶ 正则函数接口:
- vector<vector<int> > findall(const char \*regex, const char \*content)
- 函数功能
  - 返回正则表达式在文本中的所有匹配
- > 函数参数
  - ▶ regex: 正则表达式
  - ▶ content: 文本
- 返回结果
  - ▶ 返回正则表达式在文本中的所有匹配(外层vector)
  - 每一次匹配(内层vector)包含所有捕获块的文本匹配范围,其中每相邻两个整数表示一个捕获块范围(捕获块为圆括号包含起来的子表达式匹配到的内容)
  - 捕获块从0开始计数,第0个捕获块表示整个正则表达式,默认总是存在
  - 捕获块范围为左闭右开区间



## 实现细节: 正则表达式引擎

```
extern vector<vector<int> > findall(const char *regex, const char *content);
int main()
1{
    char regex[] = "([a-z]+)([^a-z]+)";
    char content[] = "ab2c1def3g12ui";
    vector<vector<int> > result;
    result = findall(regex, content);
    for (int i=0; i<result.size(); i++) {</pre>
        for (int j=result[i][0]; j<result[i][1]; j++)</pre>
            printf("%c", *(content+j));
        printf(": ");
        for (int j=0; j<result[0].size(); j+=2)</pre>
            printf("(%d,%d)", result[i][j], result[i][j+1]);
        printf("\n"):
    printf("\n");
 输入:
                                        输出:
 正则: ([a-z]+)([^a-z]+)
                                        ab2: (0,3)(0,2)(2,3)
                                        c1: (3,5)(3,4)(4,5)
                                        def3: (5,9)(5,8)(8,9)
 文本: ab2c1def3g12ui
                                        q12: (9,12)(9,10)(10,12)
```



#### 实现细节: Pattern

- 可以当做对若干表进行拼接。
- ► Eg:

```
extract pattern (<C.Cap>) /,/ (<S.Stt>) 
这里 <C.Cap>是一个表中的列,<S.Stt>同理。
/,/ 匹配Cap和Stt列中元素之间是否含有逗号。
```



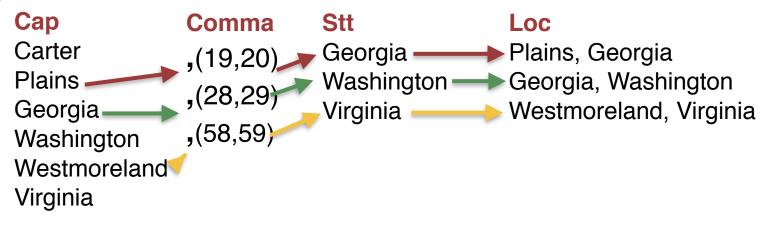
### 实现细节: Pattern

Carter\_from\_Plains,\_Georgia,
1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28

\_ Washington\_from\_Westmoreland,\_Virginia
29 30 31 32 33 34 35 36 37 38 39 40 41 42 43 44 45 46 47 48 49 50 51 52 53 54 55 56 57 58 59 60 61 62 63 64 65 66 67

按照中间只**隔了一个逗号,且后一个单词为州名**即为一个地名的规则。 pattern (<C.Cap>) /,/ (<S.Stt>)

Eg:





#### 实现细节: Pattern

- 关于 <Token>{min, max}, 这里min和max指 中间相隔了min到max个Token符合的模式。
- ▶ Eg:

extract pattern (<P.Per>) <Token>{1,2} (<L.Loc>) 指Per和Loc之间至少间隔1个token, 至多间隔两个tokens。



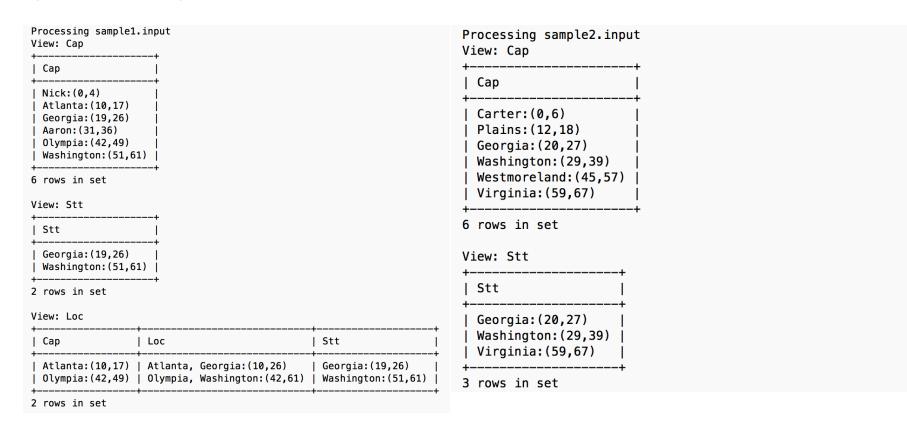
#### 实现细节: 文本 Tokenizer

- ▶ 需要一个分词器,对文本划分token。
- 划分规则:以非数字与非单词为间隔,除了空白符的一切字符或字符串都可以作为token。空白符被忽略。
- ▶ <u>[跳转]</u>到幻灯片4查看例子



# 实现细节: output 格式化输出

- output的功能是将view的内容进行格式化输出
- (参考下图)





# 实现细节: output 格式化输出

#### ▶ 格式:

- ▶ 正在处理的文本,开头打印Processing sample.input
- ▶ 打印view的名字,如果output带有别名,只打印view 的别名
- 以表格形式打印view的内容: 列名和列的内容(注意对齐)
- ▶ 表格后打印行数,若行数为0则打印「Empty set」
- ▶ 列的内容包含span的实际字符和span的位置下标
- ▶ 行、列的打印顺序无要求



## 实现细节: 错误处理

- ▶ 可选做, 无具体要求
  - ▶ 词法分析时,出现异常token,打印错误token的行 号、列号以及错误的token和错误类型,并停止运行
  - ▶ 语法分析时,出现匹配异常,打印错误token的行 号、列号以及错误的token和错误类型,并停止运行
  - (错误类型即词法错误或语法错误)



作业说明



#### 作业说明

- 组队完成(人数<=5,允许跨方向)</p>
- ▶ 使用C/C++编写, 允许使用STL
- 代码干净整洁,变量命名合理
- 产禁抄袭



#### 附加:数据集(必做)

- 任务:
  - ▶ 提供相应的AQL Subset的程序 \*.aql ,和对应数据集 \*.txt,以及此程序对文章处理的输出结果 \*.output
- > 文本来源: 国外的新闻站点、推特等
- 以一篇文章一个txt文本文件的形式存储

#### 注意:

至少需提供一种类型的数据集,即适用于同一个\*.aql 程序的数据集。同种类型的数据集需提供至少2篇文章。(将会给出示例程序和数据集)



#### 附加:阅读论文(必做)

- ▶ 论文: 『Spanners: A Formal Framework for Information Extraction 』
- ▶ 任务:
  - ▶ 阅读部分: Abstract、Introduction 和 Spanner

### 附加:中英文提取(选作,总分加5分)

- ▶ 问题1:本AQL Subset只适用于英文的信息提取。若加上中文则需对正则表达式引擎进行改造。
- 问题2:与单纯的提取英文内容不同,中文难以提取固定的有效信息。需要对\*.aql 的写法进行思考。
- ▶ 任务: 1、提供有效的AQL Subset的实现
  - 2、提供相关数据集(一篇文章存为一个txt)
  - 3、提供数据集对应的 \*.aql 程序
- 文本来源:国内微博、微信等



#### 输入文件

- ▶ \*.aql 为AQL程序文件
- ▶ \*.input 为输入文本

```
PerLoc.aal
    create view Cap as
      extract regex /[A-Z][a-z]*/
 3
        on D.text as Cap
 4
    from Document D;
    create view Stt as
      extract regex /Washington|Georgia|Virginia/
7
 8
        on D.text
        return group 0 as Stt
 9
    from Document D;
10
11
12
    create view Loc as
    extract pattern (<C.Cap>) /,/ (<S.Stt>)
13
14
    return group 0 as Loc
        and group 1 as Cap
15
16
        and group 2 as Stt
17
      from Cap C, Stt S;
```

```
1.input *

1 Carter from Plains, Georgia, Washington from Westmoreland, Virginia
```

### 执行过程

▶ ./AQL sample.aql sample.input (单一文件)







▶ 可执行文件 AQL程序 输入文本



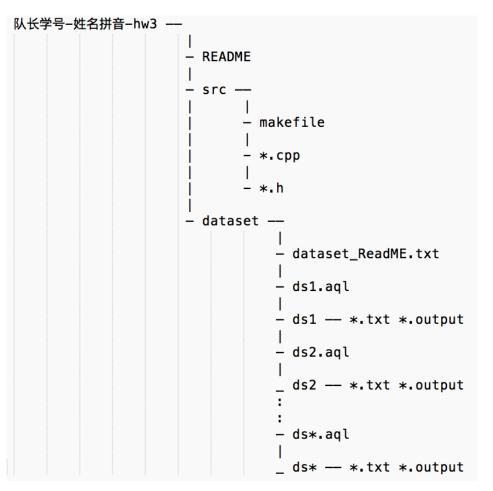




▶ ./AQL sample.aql sampleTextDir(多个输入文件 放入目录)

#### 作业提交

- ▶ 提交文件:
  - ▶ AQL Subset的源文件
  - makefile
  - ▶ 说明文档: README
  - ▶ 数据集: dataset





#### 作业提交

- 截止时间: 2015年12月31日 晚上 24: 00
- ▶ 提交方式: ftp://115.28.17.113, 账号密码sdcs
- ▶ 命名规范: 队长学号-名字拼音-hw3.zip
  - ▶ 二次提交: 队长学号-名字拼音-hw3-v2.zip



#### References

#### AQL Reference

http://www-01.ibm.com/support/knowledgecenter/#!/ SSPT3X\_2.1.2/ com.ibm.swg.im.infosphere.biginsights.aqlref.doc/ doc/aql-overview.html

